Detecção Automática de Notícias Falsas em Português: uma Comparação entre Modelos Estatísticos, BERTimbau e LLMs no FAKE.BR-Corpus

Lucas Mendes Buccini

A circulação de notícias falsas em ambientes digitais tornou-se um problema de interesse público, com efeitos sobre processos eleitorais, campanhas de saúde e a confiança da população no jornalismo. No Brasil, onde redes sociais e aplicativos de mensagens figuram entre as principais fontes de informação, esse tipo de conteúdo se espalha em velocidade muito superior à capacidade das agências de checagem, cujo trabalho é manual, minucioso e, por isso, lento. Cria-se assim um descompasso entre o volume de textos publicados diariamente e o número de verificações que profissionais humanos conseguem realizar, o que abre espaço para ferramentas computacionais capazes de fazer uma triagem inicial do conteúdo. O cenário é agravado pelo fato de que a maior parte dos recursos e estudos sobre o tema foi desenvolvida para a língua inglesa, deixando o português com menos corpora anotados e menos resultados comparativos consolidados.

Diante desse cenário, este projeto propõe construir e avaliar comparativamente pipelines de classificação capazes de distinguir notícias falsas de verdadeiras em português, partindo de modelos estatísticos simples e avançando até modelos de linguagem pré-treinados. Espera-se, com isso, não apenas obter um classificador de bom desempenho, mas sobretudo medir quanto ganho cada aumento de complexidade efetivamente traz, de modo a indicar se o custo computacional de um modelo Transformer ou de um LLM se justifica frente a uma linha de base barata e interpretável. O Processamento de Linguagem Natural é a ferramenta adequada para o problema porque a evidência disponível está no próprio texto: notícias falsas tendem a diferir das verdadeiras em vocabulário, estilo e estrutura, recorrendo com mais frequência a linguagem emotiva, exageros e construções menos formais, e esses padrões podem ser capturados por representações textuais sem depender de metadados de propagação, que raramente estão disponíveis.

Os dados virão de uma base pública e consagrada, o FAKE.BR-Corpus (Monteiro et al., 2018), disponibilizado abertamente por seus autores, de modo que não haverá coleta própria nem web scraping. O corpus reúne 7.200 notícias em português brasileiro, publicadas entre 2016 e 2018, das quais 3.600 são falsas e 3.600 são verdadeiras, e cada notícia falsa foi manualmente alinhada a uma notícia verdadeira sobre o mesmo assunto, cobrindo temas como política, celebridades, sociedade, ciência e tecnologia, economia e religião. Essa construção torna a base especialmente adequada ao problema: o balanceamento perfeito dispensa técnicas de reamostragem, e o alinhamento por assunto reduz o risco de o classificador aprender a separar temas em vez de separar veracidade. O conjunto será dividido de forma estratificada em treino, validação e teste, na proporção de 70%, 15% e 15% (5.040, 1.080 e 1.080 notícias),

tomando-se o cuidado de manter cada par alinhado na mesma partição, para que o tema de uma notícia de teste não tenha sido visto durante o treinamento por meio de sua contraparte.

Como todos os textos já possuem rótulo, o projeto se enquadra no paradigma de aprendizado supervisionado, e a tarefa computacional subjacente é a classificação binária de documentos: dado o texto de uma notícia, o modelo deve atribuí-la à classe falsa ou à classe verdadeira. A primeira etapa do pipeline consiste na preparação dos dados e na construção de uma linha de base estatística. Para ela, os textos serão convertidos para minúsculas, terão URLs e caracteres espúrios removidos, serão tokenizados e passarão por remoção de stopwords com a lista do NLTK para o português, sendo então representados por vetores TF-IDF de unigramas e bigramas, que ponderam cada termo pela sua frequência no documento e pela sua raridade na coleção. Sobre essa representação serão treinados dois classificadores clássicos, o Naive Bayes Multinomial, modelo probabilístico que assume independência condicional entre os termos e serve como referência mínima, e a Máquina de Vetores de Suporte com kernel linear, reconhecidamente eficaz em espaços esparsos e de alta dimensionalidade como os produzidos pelo TF-IDF. Os hiperparâmetros de ambos serão ajustados por validação cruzada no conjunto de treino. Como palavras funcionais e pontuação podem carregar justamente o sinal estilístico que diferencia os dois tipos de notícia, a linha de base será avaliada com e sem a remoção de stopwords, o que permite verificar empiricamente o efeito dessa decisão em vez de assumi-la. A escolha desses modelos se justifica por treinarem em segundos em CPU e por serem interpretáveis, já que os pesos da SVM linear revelam quais termos mais contribuem para cada classe.

A segunda etapa emprega o BERTimbau (Souza et al., 2020), modelo BERT pré-treinado em um grande corpus de português brasileiro, que será submetido a ajuste fino para a tarefa por meio de uma camada de classificação acrescentada sobre a representação do token especial de início de sequência. Diferentemente do TF-IDF, que trata o documento como um conjunto de termos sem ordem, o BERTimbau produz representações contextuais, nas quais o vetor de cada palavra depende das demais palavras da sentença, o que lhe permite capturar negação, ironia e relações sintáticas inacessíveis à linha de base. Nessa etapa o pré-processamento será mínimo, limitado à limpeza de ruído, pois o modelo possui tokenizador próprio em subpalavras e foi treinado sobre texto natural, com maiúsculas e pontuação preservadas. Será utilizada a versão Base, com cerca de 110 milhões de parâmetros, treinada por poucas épocas com taxa de aprendizado baixa, na ordem de 2e-5, e seleção do melhor ponto de verificação pelo conjunto de validação. A terceira etapa avalia um LLM por aprendizado no contexto, sem qualquer atualização de pesos: o modelo recebe uma instrução descrevendo a tarefa, isoladamente no cenário zero-shot ou acompanhada de alguns exemplos rotulados extraídos do conjunto de treino no cenário few-shot, e deve responder com a classe da notícia. Essa abordagem representa o extremo oposto da linha de base, pois dispensa

treinamento, mas tem o maior custo por inferência, e sua inclusão permite responder se um modelo de propósito geral supera ou não um modelo menor especializado na tarefa.

Os três pipelines serão comparados no mesmo conjunto de teste por meio de acurácia, que é uma medida adequada dado o balanceamento das classes, e de precisão, revocação e F1 calculados para a classe falsa, complementados pela matriz de confusão. A distinção entre os tipos de erro importa para a aplicação: um falso negativo deixa uma notícia falsa circular, enquanto um falso positivo rotula indevidamente como falso um conteúdo legítimo. Além das métricas, será feita uma análise qualitativa dos erros de cada modelo, buscando identificar que tipos de notícia continuam difíceis mesmo para as abordagens mais sofisticadas.

Alguns desafios técnicos podem ser antecipados. O principal é um viés conhecido do próprio corpus: as notícias verdadeiras são, em média, várias vezes mais longas que as falsas, de modo que um classificador pode atingir desempenho elevado aprendendo apenas o tamanho do texto, e não seu conteúdo. Para contornar esse problema, os experimentos usarão a versão do corpus com textos de tamanho normalizado, disponibilizada pelos autores, na qual cada notícia é truncada ao comprimento da menor do seu par. Um segundo desafio é o limite de 512 tokens do BERTimbau, que obriga a truncar documentos longos e pode descartar trechos informativos, efeito que a normalização de tamanho atenua, mas não elimina. Há também uma limitação de generalização: as notícias falsas provêm de poucos sítios e de um período específico, o que permite ao modelo aprender o estilo dessas fontes ou os assuntos da época em vez de marcas gerais de desinformação, de modo que os resultados devem ser lidos como desempenho dentro do corpus, e não como garantia de funcionamento sobre notícias atuais. Soma-se a isso a ambiguidade linguística inerente ao problema, já que sátiras e textos parcialmente verdadeiros não se acomodam bem em um rótulo binário, e a possibilidade de que o LLM tenha tido contato com as notícias do corpus durante seu pré-treinamento, o que inflaria seu desempenho e precisa ser considerado na interpretação. Por fim, o custo computacional do ajuste fino e da inferência com o LLM exige planejamento diante dos limites de sessão do ambiente gratuito.

O escopo é viável para o período de três meses e para execução integral no Google Colab. A linha de base roda em CPU em poucos minutos; o ajuste fino do BERTimbau Base sobre cerca de cinco mil documentos cabe na memória da GPU gratuita do Colab e se conclui em tempo compatível com uma sessão, com pontos de verificação salvos no Google Drive para evitar perda de progresso; e a etapa com o LLM utilizará um modelo de pesos abertos quantizado, executável na mesma GPU, ou o nível gratuito de uma API, sendo avaliada, se necessário, sobre uma amostra estratificada do conjunto de teste para conter o custo. O primeiro mês será dedicado à obtenção e exploração dos dados, ao pré-processamento e à linha de base; o segundo, ao ajuste fino e à avaliação do BERTimbau; e o terceiro, aos experimentos com o LLM, à análise comparativa dos erros e à redação do relatório final. Ao término, espera-se entregar uma comparação reprodutível entre as três famílias de modelos

que indique, para a detecção de notícias falsas em português, qual delas oferece o melhor equilíbrio entre desempenho, custo e interpretabilidade.

Referências

MONTEIRO, R. A.; SANTOS, R. L. S.; PARDO, T. A. S.; ALMEIDA, T. A.; RUIZ, E. E. S.; VALE, O. A. Contributions to the Study of Fake News in Portuguese: New Corpus and Automatic Detection Results. In: *Computational Processing of the Portuguese Language (PROPOR 2018)*. Springer, 2018. p. 324–334.

SOUZA, F.; NOGUEIRA, R.; LOTUFO, R. BERTimbau: Pretrained BERT Models for Brazilian Portuguese. In: *Intelligent Systems (BRACIS 2020)*. Springer, 2020. p. 403–417.